
CNN - Sign Language Digits Recognition


Edgar Emilio González y González
emilio.gonzalez@galileo.edu.gt

Abstract

1 La brecha de comunicación entre los sordos y el público preocupa a la población
2 en general, sin tener ningún apoyo del gobierno. La escuela para sordos insta a
3 las personas a aprender el lenguaje de señas, pero aprender el lenguaje de señas
4 (SL) es difícil. Este proyecto presenta el sistema de reconocimiento de dígitos
5 utilizando la red neuronal convolucional (CNN) y un primer conjunto de datos
6 BSL que tiene 2,800 imágenes de signos de 10 dígitos estáticos recopilados de
7 diferentes voluntarios. Se evaluaron diferentes modelos SL y se compararon con el
8 modelo CNN propuesto.

9 1 Dataset

10 Se utiliza un dataset público(facilitado en una competencia de Kaggle) que está disponible para
11 poder ser utilizado sin inconvenientes. Este dataset contiene imágenes a color de 100x100, contiene
12 10 clases distintas (dígitos del 0 – 9) y contiene un total de 2800 imágenes para entrenar nuestra red.



13

14 2 Models

15 Se utilizaron dos herramientas distintas para evaluar y comparar los resultados, Keras y Pytorch. en
16 ambos modelos se utilizaron un batch de 128 y 30 epochs, se utilizó el CPU del computador y aunque
17 ambos fueron bastante lentos de ejecutar(aproximadamente 3 horas de ejecución por cada uno) se
18 tuvieron resultados satisfactorios.

2.1 Keras Framework:

Busqué lograr el objetivo mediante el uso de la red neuronal de convolución y obtener un resultado satisfactorio, llegando a tener más de un 90%. Usamos Keras framework, que era conciso y también tenía muchas herramientas y paquetes poderosos, para implementar este proyecto. Siguiendo los ejemplos y la intuición de CNN que vimos como VGG, la arquitectura de red a continuación comenzó con una pequeña cantidad de filtros y se incrementó en un factor de 2. Además, utilizamos el aumento de datos, con la ayuda de la función incorporada de Keras, para generar más datos de entrenamiento. Las imágenes se generaron cambiando la altura y el ancho de las imágenes, rotando las imágenes y haciendo zoom en las imágenes, porque queremos que nuestro modelo sea robusto para predecir imágenes en todos los escenarios.

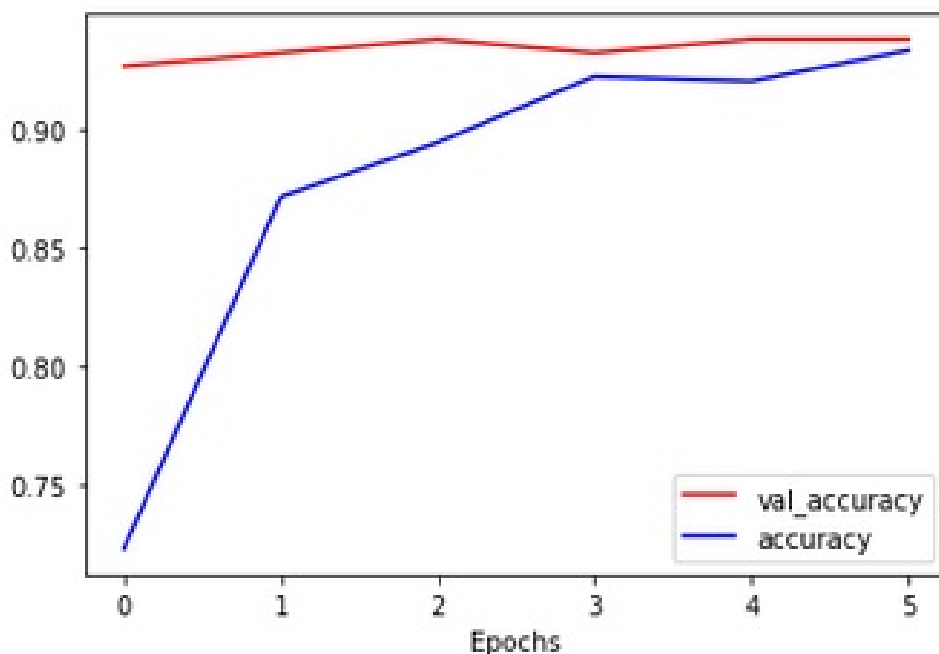
2.2 Pytorch Framework:

es un método iterativo para optimizar una función objetivo con propiedades de suavidad adecuadas (por ejemplo, diferenciable o subdiferenciable). Puede considerarse como una aproximación estocástica de la optimización del descenso del gradiente, ya que reemplaza el gradiente real (calculado a partir del conjunto de datos completo) por una estimación del mismo (calculado a partir de un subconjunto de datos seleccionado al azar). Especialmente en problemas de optimización de alta dimensión, esto reduce la carga computacional, logrando iteraciones más rápidas en el comercio para una tasa de convergencia más baja. [1]

Si bien la idea básica detrás de la aproximación estocástica se remonta al algoritmo de Robbins-Monro de la década de 1950, el descenso de gradiente estocástico se ha convertido en un método de optimización importante en el aprendizaje automático.

3 Resultados

De las dos herramientas utilizadas tanto Keras como Pytorch, Keras tuvo por mucho mejores resultados que el segundo mencionado, tanto en el entrenamiento como en la validación, es importante tener en cuenta que los números de falsos positivos son muy bajos, lo que indica que nuestro modelo podría ser implementado en un sistema transaccional sin afectar las necesidades del negocio:



46 **4 Conclusiones**

47 Se pueden tener resultados bastante satisfactorios con una red neuronal convolucional, la idea de este
48 proyecto no es quedarse así sino avanzar hasta llegar a desarrollar un sistema que pueda leer y dictar
49 el lenguaje de señas "en vivo" y estas herramientas pueden servir. Aunque los entrenamientos son
50 lentos se pueden tener grandes resultados.

51 **5 Referencias**

52 VARMEDJA, Dejan, et al. Credit card fraud detection-machine learning methods. En 2019 18th
53 International Symposium INFOTEH-JAHORINA (INFOTEH). IEEE, 2019. p. 1-5.

54 PILLAI, Thulasyammal Ramiah, et al. Credit card fraud detection using deep learning technique.
55 En 2018 Fourth International Conference on Advances in Computing, Communication Automation
56 (ICACCA). IEEE, 2018. p. 1-6.

57 ARUN, Gurumurthy Krishnamurthy; VENKATACHALAPATHY, Kaliyappan. Intelligent feature
58 selection with social spider optimization based artificial neural network model for credit card fraud
59 detection. IIOABJ, 2020, vol. 11, no 2, p. 85-91.